Πληροφοριοθεωρητική Δυναμική Απόσβεση ανά Κόμβο και Βαθμονομημένη Ομοφιλία/Ετεροφιλία για Κατηγοριοποίηση Κόμβων σε Στοχαστικά Γραφήματα

Information-Theoretic Per-Node Dynamic Damping and Trust-Calibrated Homophily/Heterophily for Node Classification in Stochastic Graphs

Ιωάννης Κωνσταντέλλος (Ioannis Konstantellos)
Τμήμα Μηχανικών Η/Υ και Πληροφορικής (CEID), Πανεπιστήμιο Πατρών

Νοέμβριος 2026

Μέρος Α: Ελληνική έκδοση

Περίληψη

Παρουσιάζουμε ένα νέο, πλήρως αυτοσυνεπές μαθηματικό και αλγοριθμικό πλαίσιο για την ημι-επιβλεπόμενη κατηγοριοποίηση κόμβων (multi-class node classification) σε ακατεύθυντα στοχαστικά γραφήματα με k κατηγορίες $\{A_0, A_1, \ldots, A_{k-1}\}$. Το προτεινόμενο μοντέλο επιλύει ενοποιημένα τρία θεμελιώδη προβλήματα της διάχυσης πληροφορίας σε γραφήματα: (i) τη βαθμονόμηση της αβεβαιότητας (trust calibration) τόσο στις πιθανότητες των ακμών όσο και στις πρωταρχικές κατανομές (priors) των κόμβων μέσω εκθετικής απόσβεσης $1 - e^{-T}$ και ισομερούς ανακατανομής μέγιστης εντροπίας, (ii) την ενσωμάτωση ομοφιλικών και ετεροφιλικών ακμών μέσω μιας δυαδικής (boolean) μεταβλητής πολικότητας και ενός κανονικοποιημένου τελεστή συμπληρώματος στο μοναδιαίο simplex, και (iii) τον ενδογενή, ανά κόμβο και ανά επανάληψη προσδιορισμό του παράγοντα απόσβεσης $\alpha_j^{(t)}$ του αλγορίθμου PageRank μέσω της θεωρίας πληροφορίας Shannon και της πιθανότητας διαφυγής $P_{\text{esc}}(j)$. Αποδεικνύουμε ότι ο προτεινόμενος κανόνας $\alpha_j^{(t)} = \frac{(H_{\max} - H')P_{\text{esc}}(j)}{(H_{\max} - H')P_{\text{esc}}(j) + (H_{\max} - H)}$ —όπου H είναι η εντροπία της πρωταρχικής κατανομής v_j του κόμβου j (του πολυ-κατηγορικού αναλόγου του x) και H' η εντροπία του εισερχόμενου σταθμισμένου σήματος των γειτόνων του $S_j^{(t)} = \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$— ισοδυναμεί με τον λόγο των αποκλίσεων Kullback–Leibler από την ομοιόμορφη κατανομή πλήρους άγνοιας, είναι αναλλοίωτος ως προς τη βάση του λογαρίθμου ($\log_2$ έναντι ln), και ικανοποιεί με απόλυτη μαθηματική συνέπεια όλες τις οριακές συνθήκες άγνοιας και βεβαιότητας.

1 Διατύπωση Προβλήματος και Προκαταρκτική Βαθμονόμηση Εμπιστοσύνης (T)

Έστω ένα ακατεύθυντο γράφημα $G = (\mathcal{V}, \mathcal{E})$ με $n = |\mathcal{V}|$ κόμβους και σύνολο $k \geq 2$ πιθανών κατηγοριών (καστών) $\mathcal{A} = \{A_0, A_1, \ldots, A_{k-1}\}$.

- Κάθε κόμβος $j \in \mathcal{V}$ διαθέτει ένα πρωταρχικό διάνυσμα πιθανοτικής κατανομής (prior distribution) $v_j = \left(v_{j,0}, v_{j,1}, \ldots, v_{j,k-1}\right)^\top \in \Delta^{k-1}$ (το πολυ-κατηγορικό ανάλογο του πρωταρχικού διανύσματος x στον αλγόριθμο εκτίμησης προσβασιμότητας), όπου $v_{j,c} \in [0, 1]$ είναι η αρχική πιθανότητα να ανήκει ο κόμβος j στην κατηγορία A_c και $\sum_{c=0}^{k-1} v_{j,c} = 1$.

- Κάθε ακμή $(i, j) \in \mathcal{E}$ διαθέτει μια πιθανότητα $p_{ij} = p_{ji} \in [0, 1]$, η οποία εκφράζει τον στοχαστικό/πιθανοτικό βαθμό ομοφιλικής ταύτισης ή ετεροφιλικής αντίθεσης μεταξύ των κόμβων i και j (διατηρώντας ταυτόχρονα την πιθανοτική ερμηνεία ανεξάρτητης ενεργοποίησης ακμής).

Στην πράξη, οι αρχικές εκτιμήσεις των πιθανοτήτων p_{ij} και v_j συνοδεύονται από διαφορετικό βαθμό αξιοπιστίας. Για τον λόγο αυτόν, κάθε αρχική πιθανότητα συνοδεύεται από έναν μη-αρνητικό δείκτη εμπιστοσύνης (trust metric) $T \in [0, \infty)$. Πριν από την εκτέλεση του κυρίως αλγορίθμου, εφαρμόζουμε το ακόλουθο προκαταρκτικό βήμα βαθμονόμησης:

1. **Βαθμονόμηση Πιθανοτήτων Ακμών:** Κάθε πιθανότητα ακμής p_{ij} με δείκτη εμπιστοσύνης $T_{ij} \geq 0$ αντικαθίσταται από:

$$p_{ij} \leftarrow p_{ij} \left(1 - e^{-T_{ij}}\right). \tag{1}$$

2. **Βαθμονόμηση Πρωταρχικών Κατανομών Κόμβων (v_j):** Κάθε συνιστώσα $v_{j,c}$ του πρωταρχικού διανύσματος v_j (με δείκτη εμπιστοσύνης $T_j \geq 0$) πολλαπλασιάζεται με τον συντελεστή $\left(1 - e^{-T_j}\right)$, και το υπόλοιπο της πιθανοτικής μάζας που υπολείπεται ώστε το διάνυσμα να αθροίζει στη μονάδα (100%), δηλαδή $1 - \left(1 - e^{-T_j}\right) \sum_{c=0}^{k-1} v_{j,c} = e^{-T_j}$, μοιράζεται **εξίσου** στις k κατηγορίες:

$$v_{j,c} \leftarrow v_{j,c} \left(1 - e^{-T_j}\right) + \frac{e^{-T_j}}{k} \quad \forall c \in \{0, \ldots, k-1\} \quad \Longleftrightarrow \quad v_j \leftarrow \left(1 - e^{-T_j}\right) v_j + \frac{e^{-T_j}}{k} \mathbf{1}_k, \tag{2}$$

όπου $\mathbf{1}_k = [1, 1, \ldots, 1]^\top \in \mathbb{R}^k$.

Πρόταση 1 (Ιδιότητες της Βαθμονόμησης Εμπιστοσύνης)**.** *Ο μετασχηματισμός* (2) *διατηρεί τη στοχαστικότητα (*$\sum_{c=0}^{k-1} v_{j,c} = 1$ *και* $v_{j,c} \geq 0$*). Για* $T_j = 0$ *(μηδενική εμπιστοσύνη) επιβάλλει την ομοιόμορφη κατανομή μέγιστης εντροπίας* $v_j = \frac{1}{k}\mathbf{1}_k$*, ενώ για* $T_j \to \infty$ *(απόλυτη εμπιστοσύνη) αφήνει το* v_j *αμετάβλητο.*

Απόδειξη. Εφόσον $T_j \geq 0$, ισχύει $1 - e^{-T_j} \in [0, 1)$ και $e^{-T_j} \in (0, 1]$, οπότε κάθε συνιστώσα $v_{j,c}\left(1 - e^{-T_j}\right) + \frac{e^{-T_j}}{k}$ είναι αυστηρά μη-αρνητική. Αθροίζοντας επί όλων των k κατηγοριών λαμβάνουμε $\left(1 - e^{-T_j}\right) \sum_{c=0}^{k-1} v_{j,c} + \sum_{c=0}^{k-1} \frac{e^{-T_j}}{k} = \left(1 - e^{-T_j}\right) \cdot 1 + k \cdot \frac{e^{-T_j}}{k} = 1$. Για $T_j = 0$ έχουμε $1 - e^0 = 0 \implies v_j = \frac{1}{k}\mathbf{1}_k$, ενώ για $T_j \to \infty$ έχουμε $e^{-T_j} \to 0 \implies v_j \to v_j$. □

Μετά την εκτέλεση των (1)–(2), όλες οι πιθανότητες p_{ij} και v_j θεωρούνται πλέον απολύτως βαθμονομημένες (ισοδύναμα με $T \to \infty$) και εισερχόμαστε στον κυρίως αλγόριθμο.

2 Κατευθυνόμενα Λογαριθμικά Βάρη w_{nj}, Πιθανότητα Διαφυγής $P_{\text{esc}}(j)$ και Τελεστής Ετεροφιλίας

Συμβολίζουμε με $V_j^{(t)} = \left(V_{j,0}^{(t)}, \ldots, V_{j,k-1}^{(t)}\right)^\top \in \Delta^{k-1}$ το διάνυσμα της προσεγγιζόμενης πιθανοτικής κατανομής του κόμβου j στον γύρο $t \geq 0$ (με αρχικοποίηση $V_j^{(0)} = v_j$), το οποίο επιδιώκουμε να συγκλίνει στην πραγματική κατανομή συμμετοχής του κόμβου j στις k κατηγορίες.

2.1 Τα Ασύμμετρα Κανονικοποιημένα Βάρη w_{nj} και ο Δείκτης $P_{\mathsf{esc}}(j)$

Για κάθε κόμβο $j \in \mathcal{V}$ με σύνολο γειτόνων $N(j) = \{i \in \mathcal{V} : (i,j) \in \mathcal{E}\}$ και για κάθε γείτονα $n \in N(j)$, ορίζουμε το βάρος επιρροής w_{nj} του γείτονα n προς τον κόμβο j ως:

$$w_{nj} \triangleq \frac{-\ln(1-p_{nj})}{-\sum_{i\in N(j)} \ln(1-p_{ij})}. \tag{3}$$

Κρίσιμη Παρατήρηση Ασυμμετρίας ($w_{ij} \neq w_{ji}$): Παρότι το γράφημα είναι ακατεύθυντο ($p_{ij} = p_{ji}$), τα βάρη είναι εν γένει κατευθυνόμενα και ασύμμετρα ($w_{ij} \neq w_{ji}$), διότι στο w_{ij} ο παρονομαστής αθροίζει επί όλων των γειτόνων του κόμβου j (ώστε $\sum_{i\in N(j)} w_{ij} = 1$), ενώ στο w_{ji} ο παρονομαστής αθροίζει επί όλων των γειτόνων του κόμβου i (ώστε $\sum_{m\in N(i)} w_{mi} = 1$).

Παράλληλα, ο δείκτης μη-απομόνωσης (πιθανότητα διαφυγής / escape probability) του κόμβου j ορίζεται ως η πιθανότητα να είναι ενεργή τουλάχιστον μία από τις προσπίπτουσες σε αυτόν ακμές:

$$P_{\mathsf{esc}}(j) \triangleq 1 - \prod_{i\in N(j)} (1-p_{ij}) \in [0,1]. \tag{4}$$

2.2 Η Δυαδική Μεταβλητή Πολικότητας και η Κανονικοποιημένη Αντιστροφή Ετεροφιλίας

Κάθε ακμή $(i,j) \in \mathcal{E}$, πέραν της πιθανότητας p_{ij}, φέρει μια δυαδική (boolean) μεταβλητή $h_{ij} \in \{0,1\}$:

- $h_{ij} = 0$: η σχέση μεταξύ i και j είναι **ομοφιλική** (έλξη / ομοιότητα κατηγορίας).
- $h_{ij} = 1$: η σχέση μεταξύ i και j είναι **ετεροφιλική** (άπωση / αντίθεση κατηγορίας).

Όταν κατά την επανάληψη στον κόμβο j συγκεντρώνεται η πληροφορία από τους γείτονες $i \in N(j)$, ο κόμβος j «βλέπει» την κατανομή $V_i^{(t)}$ κάθε γείτονα i ως $\tilde{V}_i^{(j,t)}$: αν $h_{ij} = 0$, τη βλέπει αυτούσια· αν $h_{ij} = 1$, αντικαθιστά κάθε τιμή $V_{i,c}^{(t)}$ με το συμπλήρωμά της $1 - V_{i,c}^{(t)}$ και κανονικοποιεί ώστε οι k συνιστώσες να αθροίζουν ξανά στη μονάδα:

$$\tilde{V}_i^{(j,t)} \triangleq \begin{cases} V_i^{(t)}, & \text{αν } h_{ij} = 0 \quad (\text{ομοφιλική ακμή}), \\ \dfrac{\mathbf{1}_k - V_i^{(t)}}{\sum_{c=0}^{k-1} \left(1 - V_{i,c}^{(t)}\right)} = \dfrac{\mathbf{1}_k - V_i^{(t)}}{k-1}, & \text{αν } h_{ij} = 1 \quad (\text{ετεροφιλική ακμή}), \end{cases} \tag{5}$$

διότι $\sum_{c=0}^{k-1}(1 - V_{i,c}^{(t)}) = k - \sum_{c=0}^{k-1} V_{i,c}^{(t)} = k - 1$.

- **Παράδειγμα 1 ($k = 2$):** Αν $V_i = [0.7, 0.3]^\top$ και $h_{ij} = 1$, τότε $\tilde{V}_i^{(j)} = \frac{[1-0.7,\, 1-0.3]^\top}{2-1} = [0.3, 0.7]^\top$.
- **Παράδειγμα 2 ($k = 3$):** Αν $V_i = \left[\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right]^\top$ και $h_{ij} = 1$, τότε $\mathbf{1}_3 - V_i = \left[\frac{1}{2}, \frac{3}{4}, \frac{3}{4}\right]^\top$ με άθροισμα 2, οπότε μετά την κανονικοποίηση ο κόμβος j βλέπει $\tilde{V}_i^{(j)} = \left[\frac{1}{4}, \frac{3}{8}, \frac{3}{8}\right]^\top$.

Πρόταση 2 (Αναλλοιωτότητα Simplex και Φασματική Ιδιότητα του Τελεστή Ετεροφιλίας)**.** *Ο τελεστής ετεροφιλικής αντιστροφής $\mathcal{C}(V) \triangleq \frac{\mathbf{1}_k - V}{k-1}$ απεικονίζει το μοναδιαίο simplex Δ^{k-1} στον εαυτό του ($\mathcal{C}(\Delta^{k-1}) \subseteq \Delta^{k-1}$). Επιπλέον, γράφοντας κάθε κατανομή ως $V = u + \delta$ όπου $u = \frac{1}{k}\mathbf{1}_k$ και $\sum_{c=0}^{k-1} \delta_c = 0$, ισχύει:*

$$\mathcal{C}(u+\delta) = u - \frac{1}{k-1}\delta, \qquad \mathcal{C}\big(\mathcal{C}(u+\delta)\big) = u + \frac{1}{(k-1)^2}\delta. \tag{6}$$

Συνεπώς, ο $\mathcal{C}$ έχει ακριβή ιδιοτιμή $\lambda_\perp = -\frac{1}{k-1}$ στον υποχώρο μηδενικού αθροίσματος, διατηρώντας όλες τις πιθανότητες αυστηρά μη-αρνητικές (ώστε η εντροπία Shannon να ορίζεται πάντοτε) και αποκαθιστώντας την αρχική διάταξη κλάσεων σε μονοπάτια δύο διαδοχικών ετεροφιλικών ακμών.

Απόδειξη. Για κάθε $V \in \Delta^{k-1}$ ισχύει $V_c \in [0,1]$, άρα $1 - V_c \geq 0$ και $\sum_{c=0}^{k-1} \frac{1-V_c}{k-1} = \frac{k-1}{k-1} = 1$, επομένως $\mathcal{C}(V) \in \Delta^{k-1}$. Θέτοντας $V = \frac{1}{k}\mathbf{1}_k + \delta$ με $\mathbf{1}_k^\top \delta = 0$, έχουμε:

$$\mathcal{C}(u+\delta) = \frac{\mathbf{1}_k - \frac{1}{k}\mathbf{1}_k - \delta}{k-1} = \frac{\frac{k-1}{k}\mathbf{1}_k - \delta}{k-1} = \frac{1}{k}\mathbf{1}_k - \frac{1}{k-1}\delta = u - \frac{1}{k-1}\delta.$$

Εφαρμόζοντας τον $\mathcal{C}$ δεύτερη φορά προκύπτει $\mathcal{C}(\mathcal{C}(u+\delta)) = u + \frac{1}{(k-1)^2}\delta$. □

3 Ο Πληροφοριοθεωρητικός Κανόνας Δυναμικής Απόσβεσης $\alpha_j^{(t)}$

Σε κάθε επαναληπτικό βήμα (γύρο) $t \geq 0$ και σε κάθε κόμβο $j \in \mathcal{V}$, έστω $S_j^{(t)} \in \Delta^{k-1}$ η σταθμισμένη εισερχόμενη κατανομή από τους γείτονες του κόμβου j:

$$S_j^{(t)} \triangleq \sum_{i \in N(j)} w_{ij}\, \tilde{V}_i^{(j,t)}. \tag{7}$$

Η ανανέωση της κατανομής V_j του κόμβου j εκτελείται μέσω του επαναληπτικού κανόνα τύπου PageRank με δυναμικό συντελεστή απόσβεσης $\alpha_j^{(t)}$ ανά κόμβο και ανά επανάληψη:

$$\boxed{V_j^{(t+1)} \leftarrow \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} \sum_{i \in N(j)} w_{ij}\, \tilde{V}_i^{(j,t)} = \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} S_j^{(t)}.} \tag{8}$$

Για τον υπολογισμό του $\alpha_j^{(t)}$, χρησιμοποιούμε την εντροπία Shannon μιας διακριτής κατανομής $P = (P_0, \ldots, P_{k-1})^\top \in \Delta^{k-1}$ (με τη σύμβαση $0 \ln 0 = 0$), χρησιμοποιώντας τον φυσικό λογάριθμο ln αντί του $\log_2$ χάριν υπολογιστικής αποδοτικότητας:

$$H(P) \triangleq -\sum_{c=0}^{k-1} P_c \ln P_c \in [0, H_{\max}], \qquad \text{όπου } H_{\max} = \ln k. \tag{9}$$

Συγκεκριμένα, στον κόμβο j και στον γύρο t ορίζουμε:

- $H \triangleq H(v_j) = -\sum_{c=0}^{k-1} v_{j,c} \ln v_{j,c}$: την εντροπία της πρωταρχικής πιθανοτικής κατανομής v_j του κόμβου j (του πολυ-κατηγορικού αναλόγου του πρωταρχικού διανύσματος x),
- $H' \triangleq H\left(S_j^{(t)}\right) = -\sum_{c=0}^{k-1} S_{j,c}^{(t)} \ln S_{j,c}^{(t)}$: την εντροπία της σταθμισμένης εισερχόμενης κατανομής $S_j^{(t)} = \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$ των γειτόνων του κόμβου j στον γύρο t, και
- $H_{\max} = \ln k$: τη μέγιστη δυνατή εντροπία, η οποία επιτυγχάνεται αν και μόνο αν η κατανομή είναι η ομοιόμορφη κατανομή πλήρους άγνοιας $u = \left[\frac{1}{k}, \frac{1}{k}, \ldots, \frac{1}{k}\right]^\top$.

Ο δυναμικός συντελεστής απόσβεσης $\alpha_j^{(t)}$ ορίζεται από την κλειστή σχέση:

$$\boxed{\alpha_j^{(t)} \triangleq \frac{(H_{\max} - H')\, P_{\text{esc}}(j)}{(H_{\max} - H')\, P_{\text{esc}}(j) + (H_{\max} - H)},} \tag{10}$$

συνοδευόμενη από την ακόλουθη ρητή οριακή συνθήκη πλήρους άγνοιας:

$$\textbf{Οριακή Συνθήκη:} \quad \text{Αν } H = H' = H_{\max}, \quad \text{τότε } V_j^{(t+1)} \leftarrow \left[\frac{1}{k}, \frac{1}{k}, \ldots, \frac{1}{k}\right]^\top. \tag{11}$$

Θεώρημα 1 (Πληροφοριοθεωρητική Θεμελίωση και Οριακή Ακρίβεια του $\alpha_j^{(t)}$)**.** *Για τον δυναμικό κανόνα* (8)–(11) *με* $H = H(v_j)$ *και* $H' = H(S_j^{(t)})$ *ισχύουν τα εξής:*

(i) ***Ταυτότητα Απόκλισης Kullback–Leibler (Negentropy Odds Ratio):*** *Για κάθε κατανομή* $P \in \Delta^{k-1}$*, η διαφορά* $H_{\max} - H(P)$ *ισούται ταυτοτικά με την απόκλιση Kullback–Leibler της* P *από την ομοιόμορφη κατανομή πλήρους άγνοιας* $u = \frac{1}{k}\mathbf{1}_k$*:*

$$H_{\max} - H(P) = \ln k + \sum_{c=0}^{k-1} P_c \ln P_c = \sum_{c=0}^{k-1} P_c \ln\left(\frac{P_c}{1/k}\right) = D_{\mathrm{KL}}(P \,\|\, u) \geq 0. \tag{12}$$

Επομένως, όταν $H < H_{\max}$ *και* $H' < H_{\max}$*, ο λόγος του βάρους δικτύου* $\alpha_j^{(t)}$ *προς το βάρος αυτο-διατήρησης* $1 - \alpha_j^{(t)}$ *ισούται με τον λόγο της πληροφορίας KL της γειτονιάς προς την πληροφορία KL του prior, σταθμισμένο με το* $P_{\mathrm{esc}}(j)$*:*

$$\frac{\alpha_j^{(t)}}{1 - \alpha_j^{(t)}} = \frac{H_{\max} - H'}{H_{\max} - H} P_{\mathrm{esc}}(j) = \frac{D_{\mathrm{KL}}\left(S_j^{(t)} \,\middle\|\, u\right)}{D_{\mathrm{KL}}(v_j \,\|\, u)} P_{\mathrm{esc}}(j). \tag{13}$$

(ii) ***Αναλλοιωτότητα ως προς τη Βάση του Λογαρίθμου:*** *Η αντικατάσταση του* $\log_2$ *από τον φυσικό λογάριθμο* ln *πολλαπλασιάζει τα* $H_{\max}, H, H'$ *με την ίδια θετική σταθερά* $\ln 2$*, η οποία απλοποιείται ταυτοτικά στον αριθμητή και στον παρονομαστή της* (10)*, αφήνοντας το* $\alpha_j^{(t)}$ *απολύτως αμετάβλητο.*

(iii) ***Ακριβής Συμπλήρωση των Οριακών Καθεστώτων (Και Απουσία Δυναμικού Παγώματος):***

- ***Καθεστώς 1 (****$H = H_{\max}$* ***και*** *$H' = H_{\max}$* ***— Πλήρης Άγνοια Κόμβου και Γειτονιάς στον Γύρο*** *t****):*** *Εφόσον* $D_{\mathrm{KL}}(P \,\|\, u) = 0 \iff P = u$*, η συνθήκη* $H = H' = H_{\max}$ *ισχύει αν και μόνο αν στον γύρο* t *τόσο το πρωταρχικό διάνυσμα* $v_j = u$ *όσο και το εισερχόμενο σήμα των γειτόνων* $S_j^{(t)} = u$ *είναι ομοιόμορφα. Τότε, για οποιαδήποτε τιμή* $\alpha \in [0, 1]$*, ο κυρτός συνδυασμός* $(1 - \alpha)v_j + \alpha S_j^{(t)} = (1 - \alpha)u + \alpha u$ *ισούται ταυτοτικά με* $u = \left[\frac{1}{k}, \ldots, \frac{1}{k}\right]^\top$*, καθιστώντας την οριακή συνθήκη* (11) *αλγεβρικά ακριβή. Επιπλέον, μόλις σε κάποιον επόμενο γύρο* $t' > t$ *η πληροφορία φτάσει σε έστω και έναν γείτονα του* j *ώστε* $S_j^{(t')} \neq u$*, η εντροπία της γειτονιάς πέφτει αυτόματα σε* $H' = H(S_j^{(t')}) < H_{\max}$*, οπότε ο κόμβος* j *εξέρχεται αμέσως από το Καθεστώς 1 και μεταβαίνει στο Καθεστώς 2!*
- ***Καθεστώς 2 (****$H = H_{\max}$* ***και*** *$H' < H_{\max}$* ***— Άγνωστος Κόμβος με Πληροφορημένη Γειτονιά):*** *Αν ο κόμβος* j *έχει πλήρη αρχική άγνοια (*$v_j = u \implies H_{\max} - H = 0$*), αλλά οι γείτονές του διαθέτουν πληροφορία (*$H' < H_{\max}$*) και* $P_{\mathrm{esc}}(j) > 0$*, η* (10) *δίνει* $\alpha_j^{(t)} = 1 \implies V_j^{(t+1)} = S_j^{(t)}$*, δηλαδή ο κόμβος υιοθετεί 100% την κατανομή της γειτονιάς του.*
- ***Καθεστώς 3 (****$H < H_{\max}$* ***και*** *$H' = H_{\max}$* ***— Πληροφορημένος Κόμβος με Αβέβαιη Γειτονιά):*** *Αν ο κόμβος* j *διαθέτει αρχική πληροφορία (*$H < H_{\max}$*), αλλά το εισερχόμενο σήμα των γειτόνων του έχει μέγιστη εντροπία (*$H' = H_{\max} \implies H_{\max} - H' = 0$*), η* (10) *δίνει* $\alpha_j^{(t)} = 0 \implies V_j^{(t+1)} = v_j$*, προστατεύοντας 100% την αρχική πεποίθηση του κόμβου από τον θόρυβο της γειτονιάς.*

Απόδειξη. Το (i) προκύπτει γράφοντας $H_{\max} - H(P) = \ln k \sum_{c=0}^{k-1} P_c + \sum_{c=0}^{k-1} P_c \ln P_c = \sum_{c=0}^{k-1} P_c \ln(kP_c) = D_{\mathrm{KL}}(P \,\|\, u)$, το οποίο είναι μη-αρνητικό από την ανισότητα Gibbs με ισότητα αν και μόνο αν $P = u$. Διαιρώντας το $\alpha_j^{(t)}$ με το $1 - \alpha_j^{(t)} = \frac{H_{\max} - H}{(H_{\max} - H')P_{\mathrm{esc}}(j) + (H_{\max} - H)}$ λαμβάνουμε την (13). Το (ii) έπεται από την ταυτότητα $H_{\log_2}(P) = \frac{1}{\ln 2} H_{\ln}(P)$. Τέλος, το (iii) έπεται άμεσα από την αυστηρή κοιλότητα της εντροπίας Shannon στο Δ^{k-1}: όταν $H = H' = H_{\max}$, το

μοναδικό μέγιστο της εντροπίας επιβάλλει $v_j = S_j^{(t)} = u$, οπότε κάθε κυρτός συνδυασμός τους ισούται με u. □

4 Σύνοψη Αλγορίθμου και Υπολογιστική Πολυπλοκότητα

Ο Πίνακας 1 συνοψίζει την πλήρη αλγοριθμική διαδικασία. Κάθε επανάληψη απαιτεί χρόνο $O(|\mathcal{E}| \cdot k + |\mathcal{V}| \cdot k)$ και μνήμη $O(|\mathcal{E}| + |\mathcal{V}| \cdot k)$.

Πίνακας 1: Αλγόριθμος 1: Πληροφοριοθεωρητική Δυναμική Διάχυση με Βαθμονομημένη Ετεροφιλία

Είσοδος: Γράφημα $G = (\mathcal{V}, \mathcal{E})$, αριθμός κατηγοριών k, αρχικές πιθανότητες ακμών p_{ij} με δείκτες εμπιστοσύνης $T_{ij} \geq 0$, δυαδικές μεταβλητές πολικότητας ακμών $h_{ij} \in \{0, 1\}$, πρωταρχικές κατανομές κόμβων $v_j \in \Delta^{k-1}$ με δείκτες εμπιστοσύνης $T_j \geq 0$, ανοχή σύγκλισης ε.
Έξοδος: Προσεγγιζόμενες κατανομές κατηγοριών $V_j \in \Delta^{k-1}$ για κάθε κόμβο $j \in \mathcal{V}$.

Προκαταρκτικό Στάδιο (Βαθμονόμηση Εμπιστοσύνης και Βαρών):

1. Για κάθε ακμή $(i, j) \in \mathcal{E}$: θέσε $p_{ij} \leftarrow p_{ij} \left(1 - e^{-T_{ij}}\right)$.
2. Για κάθε κόμβο $j \in \mathcal{V}$: θέσε $v_j \leftarrow \left(1 - e^{-T_j}\right) v_j + \frac{e^{-T_j}}{k} \mathbf{1}_k$ και υπολόγισε $H_j \leftarrow -\sum_{c=0}^{k-1} v_{j,c} \ln v_{j,c}$.
3. Για κάθε κόμβο $j \in \mathcal{V}$: υπολόγισε $P_{\text{esc}}(j) \leftarrow 1 - \prod_{i \in N(j)} (1 - p_{ij})$ και $w_{nj} \leftarrow \frac{-\ln(1-p_{nj})}{-\sum_{i \in N(j)} \ln(1-p_{ij})}$ $\forall n \in N(j)$.
4. Θέσε $H_{\max} \leftarrow \ln k$ και αρχικοποίησε $V_j^{(0)} \leftarrow v_j$ για κάθε $j \in \mathcal{V}$.

Κυρίως Επαναληπτικός Βρόχος ($t = 0, 1, 2, \ldots$):

5. **για κάθε** κόμβο $j \in \mathcal{V}$ **εκτέλεσε**
6. Για κάθε γείτονα $i \in N(j)$: αν $h_{ij} = 0$ θέσε $\tilde{V}_i^{(j,t)} \leftarrow V_i^{(t)}$, αλλιώς ($h_{ij} = 1$) θέσε $\tilde{V}_i^{(j,t)} \leftarrow \frac{\mathbf{1}_k - V_i^{(t)}}{k-1}$.
7. Υπολόγισε το εισερχόμενο σήμα γειτονιάς $S_j^{(t)} \leftarrow \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$ και την εντροπία $H'_j \leftarrow -\sum_{c=0}^{k-1} S_{j,c}^{(t)} \ln S_{j,c}^{(t)}$.
8. **αν** $H_j = H_{\max}$ **και** $H'_j = H_{\max}$ (ή $P_{\text{esc}}(j) = 0$ με $H_j = H_{\max}$) **τότε**
9. Θέσε $V_j^{(t+1)} \leftarrow \left[\frac{1}{k}, \frac{1}{k}, \ldots, \frac{1}{k}\right]^\top$.
10. **αλλιώς**
11. Υπολόγισε $\alpha_j^{(t)} \leftarrow \dfrac{(H_{\max} - H'_j) P_{\text{esc}}(j)}{(H_{\max} - H'_j) P_{\text{esc}}(j) + (H_{\max} - H_j)}$.
12. Ανανέωσε $V_j^{(t+1)} \leftarrow \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} S_j^{(t)}$.
13. **μέχρις ότου** $\max_{j \in \mathcal{V}} \|V_j^{(t+1)} - V_j^{(t)}\|_1 < \varepsilon$.

Part B: English version

Abstract

We formulate a parameter-free, self-consistent mathematical and algorithmic framework for multi-class node classification in undirected stochastic graphs across k classes $\{A_0, A_1, \ldots, A_{k-1}\}$. Our framework unifies three fundamental aspects of graph belief propagation: (i) an initial trust-calibration stage that discounts uncertain edge probabilities and node prior distributions via the exponential reliability factor $1 - e^{-T}$, redistributing residual prior mass uniformly across the k classes according to the Maximum Entropy Principle; (ii) a boolean edge-polarity mechanism ($h_{ij} \in \{0, 1\}$) that handles both homophilic and heterophilic links through a normalized simplex complement transformation; and (iii) an endogenous, per-node and per-iteration PageRank damping factor $\alpha_j^{(t)}$ derived from Shannon entropy and the node escape probability $P_{\text{esc}}(j)$. We prove that the proposed damping law $\alpha_j^{(t)} = \frac{(H_{\max} - H')P_{\text{esc}}(j)}{(H_{\max} - H')P_{\text{esc}}(j) + (H_{\max} - H)}$—where H is the Shannon entropy of node j's prior distribution v_j (the multi-class counterpart of the seed vector x) and H' is the entropy of its aggregated incoming neighborhood distribution $S_j^{(t)} = \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$—equals the Kullback–Leibler information odds ratio relative to uniform ignorance, is invariant to the choice of logarithm base ($\log_2$ vs. ln), and satisfies all boundary conditions of complete ignorance and certainty.

1 Problem Formulation and Trust-Based Prior Calibration (T)

Consider an undirected graph $G = (\mathcal{V}, \mathcal{E})$ with $n = |\mathcal{V}|$ vertices and $k \geq 2$ target classes $\mathcal{A} = \{A_0, A_1, \ldots, A_{k-1}\}$.

- Each vertex $j \in \mathcal{V}$ is associated with an initial prior probability vector $v_j = \left(v_{j,0}, v_{j,1}, \ldots, v_{j,k-1}\right)^\top \in \Delta^{k-1}$ (the multi-class counterpart of the seed vector x in reachability diffusion), where $v_{j,c} \in [0, 1]$ denotes the prior probability that vertex j belongs to class A_c and $\sum_{c=0}^{k-1} v_{j,c} = 1$.
- Each edge $(i, j) \in \mathcal{E}$ carries a probability $p_{ij} = p_{ji} \in [0, 1]$ representing the stochastic degree of homophilic identification or heterophilic opposition between vertices i and j, while simultaneously retaining its interpretation as an independent edge-existence probability.

Because initial estimates of p_{ij} and v_j carry varying degrees of confidence in real-world applications, each probability is accompanied by a trust index $T \in [0, \infty)$. Prior to iterative propagation, we execute a one-time calibration step:

1. **Edge Probability Calibration:** Each edge probability p_{ij} with trust $T_{ij} \geq 0$ is discounted as
$$p_{ij} \leftarrow p_{ij} \left(1 - e^{-T_{ij}}\right). \tag{1}$$
2. **Node Prior Calibration:** Each component $v_{j,c}$ of the prior vector v_j (with trust $T_j \geq 0$) is scaled by $\left(1 - e^{-T_j}\right)$, and the residual probability mass $1 - \left(1 - e^{-T_j}\right) \sum_{c=0}^{k-1} v_{j,c} = e^{-T_j}$ required for the distribution to sum to 1 (100%) is divided **equally** among all k classes:
$$v_{j,c} \leftarrow v_{j,c} \left(1 - e^{-T_j}\right) + \frac{e^{-T_j}}{k} \quad \forall c \in \{0, \ldots, k-1\} \quad \Longleftrightarrow \quad v_j \leftarrow \left(1 - e^{-T_j}\right) v_j + \frac{e^{-T_j}}{k} \mathbf{1}_k. \tag{2}$$

Once (1)–(2) have been applied, all resulting probabilities p_{ij} and v_j are treated as fully calibrated (equivalent to $T \to \infty$).

2 Directional Logarithmic Weights w_{nj}, Escape Probability $P_{\mathsf{esc}}(j)$, and Boolean Heterophily Inversion

Let $V_j^{(t)} = \left(V_{j,0}^{(t)}, \ldots, V_{j,k-1}^{(t)}\right)^\top \in \Delta^{k-1}$ denote the estimated class probability distribution of vertex j at iteration $t \geq 0$ (initialized at $V_j^{(0)} = v_j$).

2.1 Asymmetric Row-Normalized Weights w_{nj} and Escape Index $P_{\mathsf{esc}}(j)$

For every vertex $j \in \mathcal{V}$ and each neighbor $n \in N(j)$, the transition weight w_{nj} assigned by vertex j to neighbor n is defined by

$$w_{nj} \triangleq \frac{-\ln(1-p_{nj})}{-\sum_{i \in N(j)} \ln(1-p_{ij})}. \tag{3}$$

Note on Directional Asymmetry ($w_{ij} \neq w_{ji}$): In general, $w_{ij} \neq w_{ji}$ because the denominator of w_{ij} sums over the neighborhood $N(j)$ of vertex j (so $\sum_{i \in N(j)} w_{ij} = 1$), whereas the denominator of w_{ji} sums over the neighborhood $N(i)$ of vertex i.

The non-isolation index (escape probability) of vertex j is defined as

$$P_{\mathsf{esc}}(j) \triangleq 1 - \prod_{i \in N(j)} (1 - p_{ij}) \in [0,1]. \tag{4}$$

2.2 Boolean Edge Polarity and Simplex Complement Transformation

In addition to p_{ij}, each edge $(i,j) \in \mathcal{E}$ carries a boolean polarity flag $h_{ij} \in \{0,1\}$ (0 for a homophilic relationship, 1 for a heterophilic relationship). When vertex j aggregates the distribution $V_i^{(t)}$ of neighbor $i \in N(j)$, it observes the effective distribution $\tilde{V}_i^{(j,t)}$:

$$\tilde{V}_i^{(j,t)} \triangleq \begin{cases} V_i^{(t)}, & \text{if } h_{ij} = 0 \quad (\text{homophilic edge}), \\ \dfrac{\mathbf{1}_k - V_i^{(t)}}{\sum_{c=0}^{k-1} \left(1 - V_{i,c}^{(t)}\right)} = \dfrac{\mathbf{1}_k - V_i^{(t)}}{k-1}, & \text{if } h_{ij} = 1 \quad (\text{heterophilic edge}). \end{cases} \tag{5}$$

For example, if $k = 2$ and $V_i = [0.7, 0.3]^\top$ with $h_{ij} = 1$, vertex j observes $\tilde{V}_i^{(j)} = [0.3, 0.7]^\top$; if $k = 3$ and $V_i = \left[\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right]^\top$ with $h_{ij} = 1$, then $\mathbf{1}_3 - V_i = \left[\frac{1}{2}, \frac{3}{4}, \frac{3}{4}\right]^\top$, which normalizes to $\tilde{V}_i^{(j)} = \left[\frac{1}{4}, \frac{3}{8}, \frac{3}{8}\right]^\top$.

Proposition 1 (Simplex Preservation and Eigenvalue of Heterophily Inversion)**.** The complement operator $\mathcal{C}(V) \triangleq \frac{\mathbf{1}_k - V}{k-1}$ maps Δ^{k-1} into itself. Writing $V = u + \delta$ with $u = \frac{1}{k}\mathbf{1}_k$ and $\sum_{c=0}^{k-1} \delta_c = 0$, we have $\mathcal{C}(u+\delta) = u - \frac{1}{k-1}\delta$ and $\mathcal{C}(\mathcal{C}(u+\delta)) = u + \frac{1}{(k-1)^2}\delta$.

Proof. For any $V \in \Delta^{k-1}$, $1 - V_c \geq 0$ and $\sum_{c=0}^{k-1} \frac{1-V_c}{k-1} = \frac{k-1}{k-1} = 1$, so $\mathcal{C}(V) \in \Delta^{k-1}$. Substituting $V = \frac{1}{k}\mathbf{1}_k + \delta$ gives $\mathcal{C}(u+\delta) = \frac{(1-1/k)\mathbf{1}_k - \delta}{k-1} = u - \frac{1}{k-1}\delta$, and applying $\mathcal{C}$ a second time yields $u + \frac{1}{(k-1)^2}\delta$. □

3 Information-Theoretic Dynamic Per-Node Damping $\alpha_j^{(t)}$

At each iteration $t \geq 0$ and vertex $j \in \mathcal{V}$, let $S_j^{(t)} \triangleq \sum_{i \in N(j)} w_{ij}\, \tilde{V}_i^{(j,t)} \in \Delta^{k-1}$ denote the aggregated incoming neighborhood distribution. Vertex j updates its class distribution via the PageRank-type iteration:

$$\boxed{V_j^{(t+1)} \leftarrow \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} \sum_{i \in N(j)} w_{ij}\, \tilde{V}_i^{(j,t)} = \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} S_j^{(t)}.} \tag{6}$$

Using the natural logarithm ln for computational efficiency, let $H(P) = -\sum_{c=0}^{k-1} P_c \ln P_c$ be the Shannon entropy of a distribution $P \in \Delta^{k-1}$, and let:

- $H \triangleq H(v_j) = -\sum_{c=0}^{k-1} v_{j,c} \ln v_{j,c}$ be the entropy of vertex j's prior distribution v_j (the multi-class counterpart of the seed vector x),
- $H' \triangleq H\left(S_j^{(t)}\right) = -\sum_{c=0}^{k-1} S_{j,c}^{(t)} \ln S_{j,c}^{(t)}$ be the entropy of the incoming neighborhood distribution $S_j^{(t)} = \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$ at iteration t, and
- $H_{\mathsf{max}} = \ln k$ be the maximum entropy attained at the uniform distribution $u = \left[\frac{1}{k}, \ldots, \frac{1}{k}\right]^\top$.

The dynamic damping factor $\alpha_j^{(t)}$ is defined by

$$\boxed{\alpha_j^{(t)} \triangleq \frac{(H_{\mathsf{max}} - H')\, P_{\mathsf{esc}}(j)}{(H_{\mathsf{max}} - H')\, P_{\mathsf{esc}}(j) + (H_{\mathsf{max}} - H)},} \tag{7}$$

subject to the explicit boundary condition:

$$\textbf{Boundary Rule:} \quad \text{If } H = H' = H_{\mathsf{max}}, \quad \text{then } V_j^{(t+1)} \leftarrow \left[\frac{1}{k}, \frac{1}{k}, \ldots, \frac{1}{k}\right]^\top. \tag{8}$$

Theorem 1 (Information-Theoretic Foundations and Boundary Consistency)**.** For the dynamic iteration (6)–(8) with $H = H(v_j)$ and $H' = H(S_j^{(t)})$:

(i) **Kullback–Leibler Divergence Identity:** For any $P \in \Delta^{k-1}$, $H_{\mathsf{max}} - H(P) = D_{\mathsf{KL}}(P \,\|\, u) \geq 0$, where $u = \frac{1}{k}\mathbf{1}_k$. Hence, whenever $H < H_{\mathsf{max}}$ and $H' < H_{\mathsf{max}}$, the damping-to-retention odds ratio is

$$\frac{\alpha_j^{(t)}}{1 - \alpha_j^{(t)}} = \frac{H_{\mathsf{max}} - H'}{H_{\mathsf{max}} - H}\, P_{\mathsf{esc}}(j) = \frac{D_{\mathsf{KL}}\left(S_j^{(t)} \,\middle\|\, u\right)}{D_{\mathsf{KL}}(v_j \,\|\, u)}\, P_{\mathsf{esc}}(j). \tag{9}$$

(ii) **Base Invariance:** Replacing $\log_2$ with ln scales H_{max}, H, H' by $\ln 2$, which cancels in (7).

(iii) **Exactness of Boundary Regimes (and Absence of Dynamical Freezing):**

- **Regime 1 ($H = H_{\mathsf{max}}$ and $H' = H_{\mathsf{max}}$ — Complete Node and Neighborhood Ignorance at Step t):** Since $D_{\mathsf{KL}}(P \,\|\, u) = 0 \iff P = u$, the condition $H = H' = H_{\mathsf{max}}$ holds if and only if both $v_j = u$ and $S_j^{(t)} = u$ are uniform at step t. Then $(1-\alpha)v_j + \alpha S_j^{(t)} = \frac{1}{k}\mathbf{1}_k$ for every $\alpha \in [0,1]$, making (8) algebraically exact. Moreover, as soon as class information reaches any neighbor of j at a subsequent iteration $t' > t$ so that $S_j^{(t')} \neq u$, its neighborhood entropy drops to $H' = H(S_j^{(t')}) < H_{\mathsf{max}}$, and vertex j immediately transitions out of Regime 1 into Regime 2!

- **Regime 2 ($H = H_{\max}$ and $H' < H_{\max}$ — Unlabelled Node with Informative Neighborhood):** When $v_j = u$ ($H_{\max} - H = 0$), $H' < H_{\max}$, and $P_{\text{esc}}(j) > 0$, Eq. (7) yields $\alpha_j^{(t)} = 1$ and $V_j^{(t+1)} = S_j^{(t)}$, so an initially unlabelled node fully absorbs its informative neighborhood distribution.
- **Regime 3 ($H < H_{\max}$ and $H' = H_{\max}$ — Informed Node with Uninformative Neighborhood):** When $H < H_{\max}$ and $H' = H_{\max}$ ($H_{\max} - H' = 0$), Eq. (7) yields $\alpha_j^{(t)} = 0$ and $V_j^{(t+1)} = v_j$, shielding an informed node from uninformative neighborhood noise.

Proof. Part (i) follows from $H_{\max} - H(P) = \sum_{c=0}^{k-1} P_c \ln(kP_c) = D_{\text{KL}}(P \,\|\, u) \geq 0$ by Gibbs' inequality, with equality iff $P = u$. Dividing $\alpha_j^{(t)}$ by $1 - \alpha_j^{(t)}$ yields (9). Part (ii) follows from $H_{\log_2}(P) = H_{\ln}(P)/\ln 2$. Part (iii) follows directly from the strict concavity of Shannon entropy on Δ^{k-1}. □

4 Algorithmic Summary and Complexity

Table 1 summarizes the complete procedure. Each iteration runs in $O(|\mathcal{E}| \cdot k + |\mathcal{V}| \cdot k)$ time and $O(|\mathcal{E}| + |\mathcal{V}| \cdot k)$ space.

Table 1: Algorithm 1: Information-Theoretic Dynamic Diffusion with Trust-Calibrated Heterophily

Input: Graph $G = (\mathcal{V}, \mathcal{E})$, number of classes k, initial edge probabilities p_{ij} with trust $T_{ij} \geq 0$, boolean edge polarity flags $h_{ij} \in \{0, 1\}$, node priors $v_j \in \Delta^{k-1}$ with trust $T_j \geq 0$, tolerance ε.
Output: Converged class probability distributions $V_j \in \Delta^{k-1}$ for all $j \in \mathcal{V}$.

Preprocessing Stage (Trust Calibration and Static Weights):

1. For each edge $(i, j) \in \mathcal{E}$: set $p_{ij} \leftarrow p_{ij} \left(1 - e^{-T_{ij}}\right)$.
2. For each node $j \in \mathcal{V}$: set $v_j \leftarrow \left(1 - e^{-T_j}\right) v_j + \frac{e^{-T_j}}{k} \mathbf{1}_k$ and compute $H_j \leftarrow -\sum_{c=0}^{k-1} v_{j,c} \ln v_{j,c}$.
3. For each node $j \in \mathcal{V}$: compute $P_{\text{esc}}(j) \leftarrow 1 - \prod_{i \in N(j)} (1 - p_{ij})$ and $w_{nj} \leftarrow \frac{-\ln(1-p_{nj})}{-\sum_{i \in N(j)} \ln(1-p_{ij})}$ $\forall n \in N(j)$.
4. Set $H_{\max} \leftarrow \ln k$ and initialize $V_j^{(0)} \leftarrow v_j$ for all $j \in \mathcal{V}$.

Iterative Propagation Loop ($t = 0, 1, 2, \ldots$):

5. **for each** node $j \in \mathcal{V}$ **do**
6. For each neighbor $i \in N(j)$: if $h_{ij} = 0$ set $\tilde{V}_i^{(j,t)} \leftarrow V_i^{(t)}$, else ($h_{ij} = 1$) set $\tilde{V}_i^{(j,t)} \leftarrow \frac{\mathbf{1}_k - V_i^{(t)}}{k-1}$.
7. Compute incoming neighborhood distribution $S_j^{(t)} \leftarrow \sum_{i \in N(j)} w_{ij} \tilde{V}_i^{(j,t)}$ and entropy $H'_j \leftarrow -\sum_{c=0}^{k-1} S_{j,c}^{(t)} \ln S_{j,c}^{(t)}$.
8. **if** $H_j = H_{\max}$ **and** $H'_j = H_{\max}$ (or $P_{\text{esc}}(j) = 0$ with $H_j = H_{\max}$) **then**
9. Set $V_j^{(t+1)} \leftarrow \left[\frac{1}{k}, \frac{1}{k}, \ldots, \frac{1}{k}\right]^\top$.
10. **else**
11. Compute $\alpha_j^{(t)} \leftarrow \dfrac{(H_{\max} - H'_j) P_{\text{esc}}(j)}{(H_{\max} - H'_j) P_{\text{esc}}(j) + (H_{\max} - H_j)}$.
12. Update $V_j^{(t+1)} \leftarrow \left(1 - \alpha_j^{(t)}\right) v_j + \alpha_j^{(t)} S_j^{(t)}$.
13. **until** $\max_{j \in \mathcal{V}} \|V_j^{(t+1)} - V_j^{(t)}\|_1 < \varepsilon$.